本地会话导出：Claude Code CLI Web UI、医生体验与 HCI 评估设计

不包含最初上传的 PDF 原文内容；仅整理本次对话中后续讨论形成的本地会话记录。

导出范围

> 本导出从“以 Web UI 形式让医生远程体验 Claude Code CLI/harness 项目”这一讨论开始，保留用户与助手围绕系统定位、医生体验、问卷/访谈流程、HCI 研究设计的对话。最初上传的 PDF 文件内容及其原文不纳入本文档。

对话记录

用户

是的，我准备以Web UI的形式，但我期望Claude Code CLI的回复能够忠实且完全地展示给用户，因为我的这个project本质上是基于CC CLI和harness engineering，重点在于用户和CC的交互

助手

对，这个目标和“只做一个安全评估表单”不完全一样；你的 Web UI 不应该把 CC CLI 过度抽象掉，而应该保留“用户与 CC CLI/harness 交互”的实验对象本身。

对，你这个定位要改一下：**Web UI 不是把 Claude Code CLI 压缩成一个“医生评分表”，而是把 CC CLI 的可观察交互过程搬到浏览器里**。这更符合你论文的核心：不是单纯 human evaluation，而是 **human-Claude Code CLI interaction + harness engineering**。

我会这样定义：

```
Web UI = a browser-based interaction frontend for the same Claude Code CLI harness
```

而不是：

```
Web UI = a simplified annotation interface
```

关键区别在于：**你要展示的不是“总结后的状态”，而是“忠实 transcript”**。

我建议 UI 分成三层：

```
1. Raw Claude Code Transcript
   - 完整显示 CC CLI 返回给 stdout 的 assistant message
   - 完整显示 tool use / tool result / hook event / partial message
   - 尽量不 paraphrase，不 summarize，不重写

2. Interaction Controls
   - 用户输入框
   - 数据集选择
   - 是否继续 / 是否重跑 / 是否接受建议
```

```
   - 这些输入原样记录并传回下一轮 CLI invocation

3. Safety / Context Boundary
   - 不给用户 shell
   - 不给用户任意 bash 输入
   - 不暴露真实数据路径、token、HOME、.env
   - 通过白名单 dataset manifest 和固定 harness 控制 CC CLI 能访问什么
```

也就是说，你不是要把 Claude 的回复改写成：

```
Claude 正在运行推理脚本
Claude 等待评分
Claude 已完成
```

而是要保留：

```
[Claude Code raw assistant text]
[Claude Code tool_use event]
[Claude Code tool_result event]
[Claude Code asks user a clarification question]
[User answers]
[Claude continues]
```

之前我说“不要展示完整终端”，更准确地说应该是：**不要展示可操作的 shell；但可以展示完整的 CC CLI transcript。** 这两者不矛盾。

我会把你的方案改成：

```
Doctor / evaluator browser
  |
  v
Web UI: Claude Code Interaction Frontend
  - left: dataset / case / task context
  - center: faithful Claude Code transcript
  - right: structured response controls / rating / notes
  |
  v
FastAPI backend
  - receives user message
  - appends dataset/case/harness metadata
  - invokes Claude Code CLI
  - streams raw JSONL events to frontend
  - logs everything
  |
  v
Slurm allocation
  - same project repo
  - same Claude Code CLI
  - same harness scripts
  - GPU + dataset access
```

这里最重要的是：**UI 只改变交互媒介，不改变 agentic substrate。**

你论文里可以这么写：

> We implemented a web-based interaction frontend that preserves the Claude Code CLI as the core execution substrate. The frontend does not replace the CLI agent with a custom SDK agent; instead, it streams and renders the observable Claude Code CLI transcript, tool events, and user-facing interaction points through a browser interface. This allows clinical users to interact with the same harness-driven CLI system while avoiding direct shell access to the cluster environment.

或者更强一点：

> The Web UI is not an abstraction layer that hides the agent. It is a faithful interaction surface for the Claude Code CLI harness.

但有一个边界必须写清楚：**“忠实且完全”只能指 Claude Code CLI 对用户可见的输出、工具调用事件、命令结果、hook 事件和用户输入记录；不应该也不能承诺展示模型隐藏 chain-of-thought。** 你可以展示 CC CLI 输出里本来就有的“thinking/status/plan/tool-use”文本，但不要说你展示了内部思维链。

所以最终版本我会这样总结：

你的 Web UI 应该是“Claude Code CLI transcript-preserving frontend”，不是“annotation UI”。它要完整保留用户与 CC CLI 的可观察交互，包括 Claude 的文字回复、工具调用、命令输出、澄清问题和用户回答；但通过 harness、白名单数据集、权限配置和日志系统，把 shell 权限、数据路径、token 和任意命令执行隔离掉。

用户

是的，我同意，我是想让医生远程用web ui体验这个project，在体验完后进行多方面评分

助手

对，这样定位非常清楚：**医生不是单纯来“标注/打分”的，而是作为真实 end user 来体验你的 Claude Code CLI + harness engineering project，然后对整个交互式系统进行多维度评价。**

这时 Web UI 应该设计成：

```
Remote Clinical User Study Interface
= Claude Code CLI interaction experience
+ controlled project environment
+ post-experience multidimensional evaluation
```

而不是普通 labeling UI。

你可以把系统分成两个阶段。

1. Experience phase：医生远程体验项目

医生登录 Web UI 后，不是直接看到一个问卷，而是进入一个“受控版 Claude Code CLI 项目体验界面”。

建议页面结构是：

```
左侧：Project / Dataset / Task Context
中间：Faithful Claude Code CLI Transcript
右侧：User Control + Notes + Later Rating
```

左侧显示 Project、可用数据集、当前任务说明，但不要暴露真实路径。

中间是你的核心。医生应该看到 **Claude Code CLI 可观察输出的完整 transcript**，包括：

```
User prompt
Claude response
Claude tool use event
Command output / script result
Claude clarification question
User answer
Claude next step
Final result
```

也就是说，你要保留 CC CLI 的交互味道，而不是把它压缩成“后台运行中”。

可以显示成类似：

```
[User]
Please build a diagnostic pipeline for melanoma vs atypical nevus using the available dataset.

[Claude Code]
I will first inspect the dataset manifest and identify available labels...

[Tool Use: Bash]
python scripts/inspect_dataset.py --dataset derm7pt_eval

[Tool Result]
Found 1,011 cases, 7-point labels available, diagnosis labels available...

[Claude Code]
The dataset supports both checklist-based evaluation and binary classification...
```

这个 transcript 应该尽量 **verbatim**，不要 paraphrase。你可以额外加一个“系统状态栏”，但不能替代原始 transcript。

右侧用户控制区可以包括：

```
Continue
Ask clarification
Select dataset
Select task
Approve controlled step
Request explanation
Stop session
Proceed to evaluation
```

但不要给医生任意 shell 输入框、任意 bash approval、文件浏览器访问 HOME、下载全量数据集按钮或修改代码权限。关键是：**医生体验的是 Claude Code CLI project，不是你的 HPC shell。**

2. Evaluation phase：体验后多维评分

体验完成后，医生进入评分页面。这里你可以设计成多维 Likert scale + 自由文本。

评分维度不要只评“结果对不对”，而要覆盖整个 agentic project experience。

可以分成 8 个维度：

```
A. Clinical usefulness
The system provides clinically meaningful assistance for the diagnostic task.
1 strongly disagree - 5 strongly agree

B. Interaction quality
The interaction with the Claude Code CLI agent felt clear and productive.
1 - 5

C. Transparency / traceability
The system made it clear what steps were being taken and why.
1 - 5

D. Trustworthiness
I would trust the system's outputs as a research assistant, given appropriate human oversight.
1 - 5

E. Error handling / uncertainty
The system appropriately communicated uncertainty, limitations, or failure cases.
1 - 5

F. Workflow fit
The system could fit into a realistic research or clinical AI development workflow.
1 - 5

G. Autonomy vs control
The system provided a good balance between autonomous execution and user control.
1 - 5

H. Overall rating
Overall, how would you rate this system as a clinician-facing AI development assistant?
1 very poor - 5 excellent
```

自由文本可以问：What was the most impressive part? What was the most concerning part? What would you change before using it again?

你的 user study 流程可以这样写：

```
Step 1. The clinician logs into the web interface.
Step 2. The clinician selects a predefined medical imaging task and a de-identified dataset.
Step 3. The web frontend launches the same Claude Code CLI harness used in the experimental system.
Step 4. The clinician interacts with the system through a transcript-preserving browser interface.
Step 5. The interface streams Claude Code CLI messages, tool events, and command outputs in real time.
Step 6. The clinician can answer clarification questions, request additional analysis, or proceed to
the next step.
Step 7. After completing the session, the clinician fills out a multidimensional evaluation form.
Step 8. The system stores the full interaction transcript, CLI event log, timestamps, task metadata,
and clinician ratings.
```

论文里可以这样描述你的 Web UI：

> We developed a browser-based interaction interface that allows clinical users to remotely experience the same Claude Code CLI-driven harness used in our system. The interface does not replace Claude Code CLI with a separate agent implementation. Instead, it invokes the CLI backend, streams the observable CLI transcript and tool events to the browser, and records the complete interaction trace for post-hoc analysis. After each session, clinicians complete a multidimensional evaluation covering clinical usefulness, interaction quality, transparency, trustworthiness, uncertainty handling, workflow fit, autonomy-control balance, and overall usability.

一句话总结：

你的 Web UI 应该完整保留 Claude Code CLI 的可观察交互 transcript，让医生远程体验同一个 CLI/harness-driven project；体验结束后，再用多维问卷评价它作为“clinician-facing agentic AI development assistant”的实用性、透明度、可信度、交互质量和工作流适配性。

用户

真的要体验完就立刻进入evaluation phase吗？我目前的粗略计划是他们体验完后问卷询问

助手

不一定，**完全没必要“体验完立刻强制进入 evaluation phase”**。你目前的粗略计划——**体验完后用问卷询问**——其实更自然，也更符合 clinician user study 的感觉。

我之前说的 “evaluation phase” 只是概念上的第二阶段，不是说 UI 流程上必须无缝跳转成考试模式。更准确应该是：

```
Phase 1: Clinician experiences the Web UI / CC CLI project
Phase 2: Clinician provides feedback through a questionnaire
```

这个 Phase 2 可以是：

```
体验结束后立即填写
```

也可以是：

```
体验结束后，通过链接填写问卷
```

甚至可以是：

```
体验结束后 + 简短访谈 + 问卷
```

你的场景里，我反而觉得**不要做得太像“系统自动跳转评分页”**。因为你不是在做一个机械的 annotation task，而是在让医生体验一个 **Claude Code CLI-driven medical AI development assistant**。体验之后给他们一个问卷链接，会更像真实用户研究。

比较合理的流程是：

```
1. 医生登录 Web UI
2. 选择/进入指定任务
3. 与 Claude Code CLI-based system 交互
4. 系统记录完整 transcript 和事件日志
5. 医生点击 Finish Session / End Trial
6. 页面显示：Thank you, please complete the questionnaire
7. 医生填写问卷，或者你后续发问卷链接
```

你可以在 Web UI 里放一个按钮：

```
Finish experience and open questionnaire
```

但不要让它感觉像强制考试。更像：

```
Thank you for testing the system.
Please complete the post-session questionnaire to evaluate your experience.
```

如果你想更自然，可以把问卷分成两类：

体验后立即问：interaction clarity、ease of use、whether the system was confusing、whether the transcript was understandable、perceived transparency、overall usability。

允许稍后思考再问：clinical usefulness、potential workflow fit、trustworthiness、what tasks this system might actually help with、what safety concerns they have、what they would change before using it again。

所以你可以设计成：

```
Post-experience questionnaire
```

而不是强行叫：

```
Evaluation phase
```

论文方法里也可以写得更柔和：

> After completing the interaction session, clinicians were asked to complete a post-experience questionnaire assessing the system along multiple dimensions, including usability, interaction quality, transparency, perceived clinical usefulness, trust, uncertainty handling, workflow fit, and overall impression.

所以最终建议是：

不需要体验完立刻进入一个正式 evaluation 页面。更自然的设计是：医生完成一次 Web UI 体验后，点击结束 session，然后填写 post-experience questionnaire。问卷可以嵌在 Web UI 里，也可以用外部问卷链接。你论文里把它称为 post-experience multidimensional questionnaire 就可以了。

用户

体验结束后 + 简短访谈 + 问卷 我觉得这个建议不错。另外，从HCI领域角度，你觉得是在用户体验之前就告知评分的维度比较好，还是体验之后再告诉他们评价标准？哪一种是行业普遍采用的模式？

助手

我会从 HCI/user study 的“避免 priming”和“伦理 informed consent”两条线来判断；这里不是简单二选一，而是要区分“任务目标”和“评价维度”。

从 HCI / UX research 角度，我建议你采用：

```
体验前：告知研究目的和大类评价方向，但不要展示完整评分表/具体评价标准
体验中：让医生自然完成任务，不不断提醒他们“请关注透明度/可信度/安全性”
体验后：先让他们完成结构化问卷，再做简短访谈追问原因
```

也就是说，不是完全不告知，也不是一开始就把所有 Likert items 摊开给他们看。

更常见的是：**pre-brief broadly, measure after use**。

在 usability testing 里，研究者通常会在开始前说明研究目的、任务场景、录音录像、数据用途，并强调“我们测试的是系统，不是你”；但不会提前把完整问卷和评分维度逐条给参与者看。原因是 HCI 很怕 **priming / demand characteristics**：如果你提前告诉医生“等会儿请评价透明度、可信度、不确定性处理”，他们在体验时会刻意按这些维度观察系统，交互行为就不再自然。

为什么不建议体验前展示完整评分维度？因为你的系统重点是：

```
医生真实体验 Claude Code CLI + harness-driven project
```

如果你体验前就给他们看完整评分表，比如：

```
Please rate:
- transparency
- uncertainty handling
- autonomy-control balance
- clinical usefulness
- workflow fit
- trustworthiness
```

医生可能会变成“评审模式”，而不是“真实用户模式”。他们会刻意找透明性、刻意找不确定性表达、刻意关注 tool call 是否合理。这会提高反馈的针对性，但会降低自然交互的真实性。

尤其你的项目是 **interaction experience**，不是单纯让医生审查一个固定模型输出。所以自然体验很重要。

但也不能完全不告知。伦理和研究设计上，你需要让参与者知道大概自己在参加什么研究、系统可能做什么、数据如何记录、他们之后会被询问体验反馈。尤其你这里涉及医生、远程 Web UI、Claude Code CLI transcript、可能有医学影像任务，更应该 pre-brief。

比较合适的开场说明是：

> You will interact with a web-based interface for a Claude Code CLI-driven medical AI development assistant. The goal is to understand how clinical users experience the system during a realistic research workflow. After the session, we will ask you to provide feedback on usability, interaction quality, perceived usefulness, transparency, and safety-related concerns. We are evaluating the system, not your performance.

这个程度就够了。它告诉医生“之后会问什么大类”，但没有把具体评分题目提前暴露出来。

体验后问卷和访谈的顺序，我建议稍微改一下：

```
1. Web UI experience
2. Very short immediate free reflection
3. Structured questionnaire
4. Short semi-structured interview
```

也就是：先体验，让医生自然使用系统；然后问一个开放问题，例如：

> Before filling out the questionnaire, what is your immediate overall impression of the system?

这个可以捕捉最原始的第一反应。

然后填问卷。结构化评分最好在访谈前完成。因为如果你先访谈，你的追问可能会影响他们后面的 Likert ratings。

最后做简短访谈，访谈用来解释“为什么打这个分”。比如：

```
You rated transparency as 3/5. What made it unclear?
You rated clinical usefulness as 4/5. In what scenario would it be useful?
What was the most concerning part of the interaction?
```

这样你的 quantitative rating 和 qualitative explanation 都有了。

对你的项目，我推荐的最终流程：

```
Pre-brief:
- 告知这是 Claude Code CLI-driven medical AI development assistant
- 告知会记录 interaction transcript
- 告知之后会问 usability / usefulness / transparency / safety feedback
- 不展示完整评分表

Experience:
- 医生通过 Web UI 体验系统
- 看到 faithful CC CLI transcript
- 与系统完成一个真实任务

Immediate reflection:
- 一两个开放问题，记录第一印象

Questionnaire:
- SUS-like usability
- interaction quality
- transparency
- trust
- uncertainty handling
- autonomy-control balance
- clinical usefulness
- workflow fit
- overall impression

Short interview:
- 追问高分/低分原因
```

```
- 询问真实工作流中可能怎么用
- 询问最担心什么
```

什么时候可以提前告诉完整维度？只有一种情况我会提前告诉完整评价维度：**如果你把医生定位成 expert reviewer，而不是 naturalistic user**。

比如你明确想让医生像审稿人一样检查系统：

```
Please evaluate whether this system is safe, transparent, clinically meaningful, and suitable for clinical AI development.
```

那提前给 rubric 是合理的。但这会变成 expert review / heuristic evaluation，而不是自然用户体验测试。

你的目标更像：

```
clinician-facing agentic AI development assistant 的真实体验反馈
```

所以我建议不要提前展示完整 rubric。

一句话结论：HCI 里更普遍的模式是：体验前做 broad briefing，告知研究目的和反馈大类；不要提前展示完整评分表，以免 priming；体验后先做结构化问卷，再用简短访谈解释分数。

导出说明：本文档仅包含本地后续讨论，不包含用户最初上传的 PDF 原文内容。